

SIMD ベクトル検索をルーフラインで詰める

Go 1.26 の実験的 SIMD で、外部ライブラリなしの Pure Go ベクトル検索を高速化します。ただし闇雲には触りません — ルーフラインという1枚の地図の上で「測る → 算術強度(AI)を出す → 当たっている天井を見る → その天井を狙う手だけ打つ」を繰り返します。

📖 専門用語(レジスタ / AVX / FMA ...)に迷ったら、末尾の用語ミニ辞典(\$12)へ。

🕒 当日の最短ルート: \$00 セットアップ → \$03 ルーフラインモデル → \$04 天井を計測 → \$05 を make roofline で動かす → \$07。時間がなければここだけでも流れが掴めます。

はじめに — これは何か / 何が学べるか

これは何か: Go 1.26 の標準 SIMD(`simd/archsimd`)を使い、外部ライブラリなしの Pure Go でベクトル検索を高速化する、**読みながら手元で動かせる**教材です(Go Conference 2026・40分ワークショップ)。題材は内積によるベクトル検索。ただ速くするのではなく、**ルーフライン**という地図の上で「いまどこが詰まっているか」を測り、打つ手を選ぶのが軸です。

何が学べるか:

- Go の標準 SIMD(`archsimd`)の**書き方**と、コード生成の今(VZEROUPPER 未挿入・register spill)
- ルーフラインモデルとは** — 何で詰まっているか(演算律速/メモリ律速)を1枚で見極め、測る → 算術強度(AI)を出す → 当たっている天井を見る → その天井を狙う手だけ打つ
- SIMD が「どこで効くか」** — 演算律速なら効き(カーネル・バッチ化)、メモリ律速では効かない。それを図で判断できるようになる
- 高速化の二本柱** — SIMD(実装効率)× データ表現(再利用=バッチ / バイト削減=量子化)。そして速度と精度の両立(rerank)
- 実測の作法** — 2粒度で測る・天井をマイクロベンチで実測・`objdump` で生成コードを見る・Recall で精度を測る

対象と前提: Go の基礎が読めれば十分で、CPU アーキの予備知識は要りません(専門用語は \$12 の辞典に)。**読み方:** 上から順に通読でき、各 Stage は「なぜ → コード → どうなったか」を実行コマンドつきで追えます。

00 は始める前に — セットアップ

SIMD が走るのは **amd64(Intel/AMD)実機**。一番楽なのは **GitHub Codespaces**(amd64・ゼロインストール)で、手元が Apple Silicon でもこれなら同じ数字が出ます。

① **Codespaces(推奨)** — リポジトリの **Code** → **Codespaces** → **Create**。 **.devcontainer/** に **Go 1.26 + GOEXPERIMENT=simd** が入っているので、開いたらすぐ:

```
make test # 正しさ確認(通れば準備OK) make roofline # 各Stageの点(GFLOP/s・AI)を出す
```

② **ローカル(amd64 Linux / Windows):**

```
git clone https://github.com/po3rin/gocon2026-simd-search cd gocon2026-simd-search go
install golang.org/dl/go1.26.4@latest && go1.26.4 download # Go 1.26 を入れる make
GO=$(go env GOPATH)/bin/go1.26.4 test # GOEXPERIMENT=simd は Makefile が付与
```

③ **Apple Silicon Mac** — arm64 では SIMD は走らず、**スカラ版でテストだけ通ります**(`make GO=$(go env GOPATH)/bin/go1.26.4 test`)。SIMD の数字は **Codespaces か amd64 実機**で(理由は \$10)。**Docker の --platform linux/amd64 は代用になりません**(\$10)。

必要なもの: **Go 1.26** と **make** だけ。難しい設定は無く、**GOEXPERIMENT=simd** も Makefile が自動で付けます。

01 そもそも SIMD ってなに？

まず SIMD が無い世界から始めましょう。次の Go コードはベクトルの**内積**(かけ算の合計)です。

```
var sum float32 for i := range a { sum += a[i] * b[i] // 1個ずつ かけて 足す }
```

このループは「**1個ずつ**」処理します。**a[i]** と **b[i]** を1個取り出し、1回かけ算して、足す。CPU の命令レベルでも本当にそうで、1命令で float32 を1個しか扱いません。これを**スカラ処理**と呼びます。

SIMD(Single Instruction, Multiple Data)は、その名のとおりに「**1つの命令で複数のデータをまとめて**」処理する CPU の機能です。CPU の中には普通の変数より大きな**ベクトルレジスタ**という入れ物があり、256bit のレジスタには float32(32bit)が **8個**入ります。8個入れて掛け算命令を1回実行すると、8個分の掛け算が**同時に**終わります。この違いを図にすると次のとおりです。

スカラー vs SIMD – 1命令で処理できるデータ量



SIMD = Single Instruction, Multiple Data. Go 1.26 では GOEXPERIMENT=simd で simd/archsimd パッケージが使える(amd64限定)

図: スカラは要素を1個ずつ処理する。SIMD は1命令で8個(256bit)をまとめて処理する。

384次元の内積なら、スカラで384回かかる掛け算が SIMD なら48回で済みます。**理論上は8倍速い**わけです。ただし「理論上」と断ったのには理由があります – 実際の速さは計算の速さだけでなく**メモリからデータが届く速さ**にも左右されるからです。データが間に合わなければ、計算をいくら速くしても頭打ちになります。この差は \$O5 のルーフライン[カーネル単体 vs 全探索]で実測しながら確かめます。

Go 1.26 では `GOEXPERIMENT=simd` を付けてビルドすると `simd/archsimd` パッケージが使える、**アセンブリも cgo も書かずに**ベクトル命令を直接叩けます。メソッド呼び出しがほぼそのまま1つの CPU 命令にコンパイルされます:

```
va := archsimd.LoadFloat32x8Slice(a) // float32 を8個ロード vb :=  
archsimd.LoadFloat32x8Slice(b) acc = va.MulAdd(vb, acc) // acc += va*vb (FMA という1命令)
```

注意点:`archsimd` は今のところ **amd64(Intel/AMD)専用**。Apple Silicon の Mac(arm64)ではパッケージ自体が無く、スカラにフォールバックします。手元で SIMD を走らせたいときの選択肢は、下の**環境コラム**を参照(結論: Docker の amd64 でも代用できません)。

archsimd の API の読み方(3点)

- 型が「形」を表す — `Float32x8` = float32 が8レーン(256bit)、`Float32x16` = 16レーン(512bit=AVX-512)、`Uint64x4` = uint64×4。型を選ぶ=使う命令幅を選ぶこと。
- メソッド = 1命令(イントリンシック) —
`.MulAdd`→`VFMADD`、`.Xor`→`VPXOR`、`.OnesCount`→`VPOPCNTQ`。`LoadFloat32x8Slice` / `StoreSlice` でスライス⇔ベクトルレジスタ。ほぼそのまま機械語になります。
- 実行時に CPU を確認してから使う — 未対応 CPU で呼ぶと panic。なので自分でガードします:

```
// internal/vec/dot_simd.go var hasSIMD = archsimd.X86.AVX2() && archsimd.X86.FMA() //
MulAdd は AVX2 + FMA // internal/vec/hamming_simd.go var hasVPOPCNT =
archsimd.X86.AVX512() && archsimd.X86.AVX512VPOPCNTDQ()
```

移植のための定石はビルドタグでの実装分け。`//go:build goexperiment.simd && amd64` の SIMD 実装と、それ以外向けのスカラ実装(`dot_fallback.go` など)を用意し、`hasSIMD` が false なら `DotNaive` に退避させます(`arm64` や `Rosetta` でも安全にビルド・実行できる)。そして `VZEROUPPER` だけは Go から直接出せないなので、3行のアセンブリ `vzeroupper_amd64.s` を自作して呼んでいます — 「Pure Go で SIMD」と言いつつ、境界の1命令だけは `.s` が要るのが今の現実です。

02 題材 — ベクトル検索ってなに？

SIMD の練習台にベクトル検索を選びました。RAG やセマンティック検索を支える中核技術です。

仕組みはシンプルで、文書もクエリも「埋め込みモデル」で数百次元の数値ベクトルに変換しておき、「クエリのベクトルと内積が大きい文書 = 意味が近い文書」として上位 k 件を返します。全体の流れを図にすると次のようになります。

ベクトル検索のしくみ — 「意味が近い」を内積で測る




図: 文書とクエリをベクトルに変換し、クエリとの内積で並べて上位 k 件を返す。計算の本体は内積。

つまり計算の本体は「**内積を10万回計算する**」こと。内積は掛け算と足し算の塊なので、SIMD が最も得意とする形です。だから世のベクトルDB(Faiss、Qdrant、ClickHouse...)はみんな内部で SIMD を徹底的に使っています。それを Pure Go で追体験しよう、というのが今回の趣旨です。本ページの題材カーネルは `acc += a[i]*d[i]` (クエリ a と DB ベクトル d の内積)で、これを10万本ぶん回します。

03 ルーフラインモデルとは

ルーフラインモデルは、「このコードは何で遅いのか」を1枚の図で診断する性能モデルです(原典は Williams ら 2009、\$09)。コードが遅いとき、原因は大きく2つに分かれます — **計算そのものが重い(演算律速)**か、**データの搬送待ち(メモリ律速)**か。この2つは打つ手が正反対(前者は計算を減らす・速くする、後者は運ぶデータ量や回数を減らす)で、取り違えたまま手を入れても効きません。**まずどちらで詰まっているかを見極める** — それがルーフラインの役目です。

図は、**縦軸に性能(GFLOP/s)・横軸に算術強度(AI = 計算量 ÷ データ転送量)**を取り、その機械の物理的な上限を**屋根(ルーフ)**として描きます。屋根は2本あります — **左側はメモリ帯域で決まる右上がりの斜線**(運ぶのが間に合わない領域)と、**右側は演算ピークで決まる水平線**(計算が間に合わない領域)。どんなコードもこの屋根より上には行けません。そこに自分のコードを1点プロットすれば、**屋根のどの部分の下にいるか = 何で頭打ちかがわかり**、「縦に上げる(実装を効率化)」のか「横へ動かす(データ設計を変えて AI を上げる)」のか、次の手が図から決まります。

ルーフライン(屋根)の形 — 点を打つ前の「地図」

縦=出せる性能 / 横=算術強度。屋根は2本(メモリ斜線・演算水平線)。どんなコードもこの下にしか到達できない。
↑ 性能 (GFLOP/s)




図: ルーフラインの「屋根」。左はメモリ律速(斜線)、右は演算律速(水平線)、境目がリッジ。まだ点は打っていない、機械だけで決まる地図。

例として S02 の内積カーネル(`acc += a[i]*d[i]`)を、この図の上に置いてみましょう。横軸の位置を決めるのが算術強度 (AI) = 「メモリから1バイト運ぶごとに、何回 計算するか」 (flop/byte)です。内積は要素あたり `mul 1 + add 1 = 2 flop`、DB ベクトルを 4バイト(fp32)読むので **4 byte**(クエリ側は10万件で使い回すのでキャッシュに残り、毎回は運びません):

$$AI = 2 \text{ flop} / 4 \text{ byte} = 0.5 \text{ flop/byte}$$

AI=0.5 はとても小さい値です。いまの CPU はおおむね「1バイト運ぶ間に十数～数十回」計算できる(=リッジが十数 flop/byte あたりにある)ので、0.5 はリッジの遥か左 = メモリ律速の領域に来ます。まだ1行も最適化していない段階で、「このカーネルは構造的にメモリ待ち。縦に上げるより AI を右へ動かすのが本命だ」と図が予言してくれる — これがルーフラインモデルの効きどころです。

では、このマシンの本物の天井(斜線と水平線が実際どこにあるか)はいくつなのでしょう。それを測って図を引くのが次章です。

04 天井を計測する(実測値と方法)

前章の予言を確かめ、図を引くには、このマシンの天井そのものを知る必要があります。ルーフラインの天井は「理論ピーク(スペック式)」と「実測(マイクロベンチ)」の2系統で出せて、本ページは実測を採り

まず — これは LBNL の Empirical Roofline Toolkit や原典 Williams ら(2009)と同じ流儀(原典は §09)。すべて AWS c7i 上で `make roofline-ceiling` で再現できます。

演算ピーク (AVX2)

39 GF 実測 / 理論120

メモリ帯域

11 GB/s STREAM実測

メモリ帯域 STREAM Triad **11 GB/s** BenchmarkPeakTriadBW(単スレッド) メモリ帯域 順次read 5.9 GB/s BenchmarkPeakReadBW (スカラ縮約は発行律速で過小) SIMD全探索の達成帯域 9.2 GB/s SearchSIMD (= Triad の84%、ほぼ壁。§05 で確認) 演算ピーク AVX2 FMA(Go実測) **39 GFLOP/s** BenchmarkPeakFLOP_AVX2 演算ピーク AVX2 FMA(理論) ~120 GFLOP/s 2FMA/cyc×8lane×2flop×3.75GHz → 実測39は約1/3(33%・§07) 演算ピーク AVX-512(理論) ~240 GFLOP/s 16レーン版。図の最上段の天井。本ベンチはAVX2なので比較対象外 リッジ AI ~22 flop/byte silicon 240 / 11 (AVX2 理論120基準なら ~11)

リッジは屋根の折れ点で、 $\text{天井} \div \text{帯域} = 240 / 11 \approx 22 \text{ flop/byte}$ (最上段のシリコン理論240基準)。前章で出した内積の AI=0.5 はこの遙か左 = やはり**メモリ律速**で、この AI での上限は $0.5 \times 11 = 5.5 \text{ GFLOP/s}$ と確定します。演算天井は1本ではなく段階的(Go実測 39 / AVX2理論 120 / シリコン理論 240)にあり、図では最上段 240 を屋根に、39 と 120 をその下の**サブ天井**として描きます。

測り方(初めてでも再現できるレベルで):


- **演算天井** — レジスタ上だけで独立 FMA を連打する(メモリも依存連鎖も挟まない)。アキュムレータ 12本でFMAの「待ち時間」を隠す。BenchmarkPeakFLOP_AVX2
- **メモリ天井** — キャッシュを確実に溢れる256MB配列を1スレッドで舐める。read=検索の順次読みに対応、`triad(a=b+s*c)`=STREAMの標準指標。
- **ワークロードに合わせる** — 検索はシングルスレッドなので天井もシングルコアで測る(ソケット全体の~307GB/sではない)。数値は 2026-06-13 の実測で、Goを更新したら再計測する。

これでこのマシンの屋根(斜線=11 GB/s、水平線=39/120/240、折れ点=22)が引けました。次章では、自分のコードの点をこの屋根の上に打って、Stage ごとに動かしていきます。

05 段階を追う — コードと計測(手元で動かせる)

下が §04 で測った天井で引いた、このマシンの実測ルーフラインです(横軸=AI・縦軸=性能・斜線=メモリ天井・水平線=演算天井)。各 Stage の点が打っており、**点をクリック**すると当たっている天井と右側の Go コードに切り替わります(最初は Stage 0)。これから各 Stage で、この点を動かしていきます。

ROOFLINE



STAGE 0

素朴な for ループ(全探索)

GFLOP/S

2.85

AI

0.5

MEM天井

5.5

どの天井にも当たっていない。Mem天井(5.5)にも届かず、**依存連鎖律速**。1個ずつ足すので、前の足し算を待つ「待ち時間」が露出している。

次の一手 ↑ 命令並列性を上げる (SIMD化 + 境界の掃除)

Stage 0

● スカラ基準

2.85 GF · AI 0.5

Stage 1

● AVX2 +
VZEROUPPER

4.6 GF · AI 0.5

kernel

● 内積カーネル単
体

17 GF · AI 18

Stage 2

● クエリのバッ
チ化(exact)

17.1 GF · AI 16

Stage 3

● バイナリ量子化
(近似)

130 GF · AI 16

```
func DotNaive(a, b []float32) float32 {
    var sum float32          // アキュムレータ1本
    for i := range a {
        sum += a[i] * b[i]    // 直前のsumに依存 → 加算レイテンシが直列化
    }
    return sum
}
```

ここからは**実際のコードと、動かして出る数字**です。掲載は擬似コードではなく `internal/vec/` / `internal/index` の**実コードそのまま**。手元で動かす手順:

```
# amd64 実機 or Codespaces (arm64 Mac はスカラ版でテストのみ → §01注記・下のDockerコラム)
GOEXPERIMENT=simd go test ./... # 正しさの確認 make roofline # 各Stageの GFLOP/s・AI・
MB/query を一覧(=図に点を打つ) make bench0 / bench1 / bench2 # Stage ごとのベンチ make
roofline-batch # Stage 2: B=1 vs B=32(バッチで SIMD が効く) make recall #
Recall@10(binary vs rerank)
```

計測のしくみ — `make roofline` が「図の点の座標」を出す仕組みも Go のベンチだけで完結しています。Go の `testing` で `for b.Loop()` (Go 1.24+) を回し、`b.Elapsed()` の実時間から GFLOP/s を計算、`b.ReportMetric` で自前の指標 (AI・GFLOP/s) をベンチ出力の列として足すだけ。出力の AI と GFLOP/s がそのまま **ルーフライン上の点 (x, y)** になります。

```
// internal/index/bench_test.go - 全探索Stageの「点」を出す
func reportFloatRoofline(b *testing.B, iters int) {
    sec := b.Elapsed().Seconds()
    flop := float64(benchN) * benchDim * 2 * float64(iters) // 2 flop/要素
    bytes := float64(benchN) * benchDim * 4 // 4 byte/要素
    b.ReportMetric(flop/sec/1e9, "GFLOP/s") // ← 点の y
    b.ReportMetric(2.0/4.0, "AI(flop/byte)") // ← 点の x (=0.5)
    b.ReportMetric(bytes/1e6, "MB/query")
}

func BenchmarkSearchNaive(b *testing.B) {
    benchSetup()
    b.SetBytes(benchN * benchDim * 4) // → 標準の MB/s 表示
    iters := 0
    for b.Loop() { // Go 1.24+ : 回数と計時を自動で面倒見る
        benchIx.SearchNaive(benchQ, 10)
        iters++
    }
    reportFloatRoofline(b, iters)
}
```

同じ要領で天井そのものも実測します(`make roofline-ceiling`)— FMA をレジスタ上で連打する `BenchmarkPeakFLOP_AVX2` が演算ピーク、256MB を舐める `BenchmarkPeakReadBW/TriadBW` がメモリ帯域(詳しくは S04)。図の点も天井も、特別なプロファイラ無しに Go の標準ベンチだけで出しているのがポイントです。

Stage 0 — スカラ基準(ベースライン)

なぜ: 最適化はまず**基準点**から。素朴に「1要素ずつ」内積を回し、図のどこに点が立つかを測ります。以降の手が効いたかは、この点からの移動で判断します。検索は全ベクトルと内積して上位 k 件を返すだけ。

```
// internal/vec/dot.go
func DotNaive(a, b []float32) float32 {
    var sum float32
    for i := range a {
        sum += a[i] * b[i]           // 1個ずつ かけて 足す(前の sum に依存=直列)
    }
    return sum
}

// internal/index/index.go - 全探索
func (ix *Index) SearchNaive(q []float32, k int) []Result {
    t := newTopK(k)
    for id := 0; id < ix.N; id++ {           // 10万ベクトル全部と内積
        t.push(id, vec.DotNaive(q, ix.Vector(id)))
    }
    return t.results()
}
```

どうなったか: 全探索 27.0 ms = **2.85 GFLOP/s**、AI=0.5。図では左下、メモリ天井(5.5 GF)にすら届きません。なぜ天井未満か? **依存連鎖律速** — `sum += ...` は前の足し算が終わるまで次へ進めず、待ち時間(レイテンシ)がそのまま表に出ます。1個ずつ処理=命令レベルの並列性ゼロです(384要素 × 加算レイテンシ約2サイクル ≒ 約190ns と概算でき、実測 188ns とほぼ一致します)。

→ **次の一手:** ループラインの「どの天井にも未達なら命令並列性を上げる」に従い、**同時に複数(SIMD)**で縦に上ります。

```
$ make bench0 BenchmarkSearchNaive 27.0 ms/op 2.85 GFLOP/s 0.5 AI(flop/byte) 153.6
MB/query
```

Stage 0: AI=0.5、メモリ天井(5.5)にも未達




図: いまルーフラインのここ — AI=0.5・2.85 GFLOP/s。メモリ天井(5.5)にすら届かない左下。

Stage 1 — AVX2 で SIMD化 + VZEROUPPER

なぜ: Stage 0 は命令並列性ゼロで天井にも未達だった。ルーフラインの指示は「**縦に上れ=命令並列性を上げろ**」。そこで内積を `Float32x8`(8個同時)+ FMA に置き換えます。独立した**アキュムレータ2本**で FMA の待ち時間を隠し(1本だと前の結果待ちで直列化)、スライスを進進させて境界計算を減らす。最後の `vzeroupper()` が目立たないが重要(\$07)。

```
// internal/vec/dot_simd.go (GOEXPERIMENT=simd, amd64)
import "simd/archsimd"

func Dot(a, b []float32) float32 {
    if !hasSIMD {
        return DotNaive(a, b) // arm64 等はスカラに退避
    }
    var acc0, acc1 archsimd.Float32x8 // アキュムレータ2本で待ち時間を隠す
    for len(a) >= 16 {
        acc0 = archsimd.LoadFloat32x8Slice(a).MulAdd(archsimd.LoadFloat32x8Slice(b), acc0)
        acc1 = archsimd.LoadFloat32x8Slice(a[8:]).MulAdd(archsimd.LoadFloat32x8Slice(b[8:]), acc1)
        a = a[16:]; b = b[16:] // 前進(境界計算をループ条件に吸収)
    }
    var buf [8]float32
    acc0.Add(acc1).StoreSlice(buf[:])
    vzeroupper() // ★ SIMD→スカラ境界の掃除。Goは自動挿入しない
    sum := buf[0]+buf[1]+buf[2]+buf[3]+buf[4]+buf[5]+buf[6]+buf[7]
    for i := range a { // 8の倍数でない端数
        sum += a[i] * b[i]
    }
    return sum
}
```

どうなったか: カーネル単体は **188→41 ns = 4.6x** 速くなりました。**ところが全探索は 16.7 ms = 1.6x** しか上がりません。なぜこれほど差が出るのでしょうか。図の上では**別々の2点**だからです — カーネル単体はデータが L1 にあるため演算側にまだ余地があり、全探索は DRAM から流し読みで AI=0.5 のまま**メモリの壁(9.2 GB/s)に張り付きます**。図ではこの2つは別の場所(カーネルは右上、全探索は左)に置かれます。しかも途中には隠れ天井 VZEROUPPER があり、掃除すると 167→23ns まで改善します(\$07)。

→ **結論:** 縦はもう頭打ちで、幅を 8→16(AVX-512)に広げても天井は動きません。キャッシュブロッキングも効きません — DB ベクトルは各1回しか読まれず再利用が無いので、タイリングしても DRAM 読み出し総量は変わらないからです。次は「**縦**」ではなく「**横**」=AI を動かす番。AI を上げる道は2つ — ①再利用(クエリのバッチ化・exact)と ②バイト削減(量子化・近似)。まず①を Stage 2 で。

※ 上は要点。長さガードと「8幅の端数処理」を含む完全版は [internal/vec/dot_simd.go](#)。

```
$ make bench1 BenchmarkDotSIMD 41.0 ns/op ← カーネル単体 4.6x (DotNaive 187.8ns)
BenchmarkSearchSIMD 16.7 ms/op 9.2 GB/s ← 全探索 1.6x(メモリの壁)
```

Stage 1: 縦に上る。全探索はメモリ壁・カーネルは右上




図: いまループラインのここ — 全探索はメモリ壁(9.2 GB/s)に張り付き、カーネル単体だけ右上の別の点。

Stage 2 — クエリのバッチ化：演算律速にして SIMD を効かせる(exact)

なぜ: 全探索がメモリ律速なのは、DB ベクトル d を読んでも内積1回(2flop / 4byte)しかないから。なら d を1回ロードして B 本のクエリ全部と内積すれば、同じ転送で計算が B 倍 $\rightarrow AI \approx 0.5 \times B$ 。 $B=32$ で $AI=16$ となりリッジを越えて演算律速側へ。そこなら SIMD が効くはず — しかも精度はそのまま(exact)。事実上の GEMM 化(BLAS や Faiss のバッチ検索が速い理由)。

```
// internal/index/index.go - B本のクエリを1パスで処理(d のロードを再利用)
func (ix *Index) SearchBatchSIMD(qs [][]float32, k int) [][]Result {
    tops := make([]*topK, len(qs))
    for b := range tops { tops[b] = newTopK(k) }
    for id := 0; id < ix.N; id++ {
        d := ix.Vec(id) // ① d を1回ロード
        for b := range qs { // ② B本のクエリで使い回す(d はキャッシュ常駐)
            tops[b].push(id, vec.Dot(qs[b], d)) // SIMD内積
        }
    }
    /* 各 tops[b].results() を返す */
}
```

どうなったか: $B=32$ で SIMD が exact 検索のまま 4.3x(scalar batch 19.3ms/query $\leftrightarrow$ SIMD batch 4.49ms/query)。GFLOP/s は 4.67 $\rightarrow$ 17.1(3.7倍)、1クエリ 16.5ms $\rightarrow$ 4.49ms。 $B=1$ の 1.6x からの一変は、再利用で AI を 0.5 $\rightarrow$ 16 に上げ演算律速にしたから — まさにループラインの「横(再利用) $\rightarrow$ 縦(SIMD)が

効く」。精度は一切犠牲にしません(exact)。

(spill の 39GF 天井で 17GF 止まりだが、それでもスカラを 4.3x 引き離す)

```
$ make roofline-batch # B=1(全探索) vs B=32(バッチ)、scalar vs SIMD (c7i 実測) B=1
SearchSIMD 16.5 ms/query 4.67 GF ← SIMD 1.6x(メモリ壁) B=32 SearchBatchNaive 19.3
ms/query 3.98 GF (scalar) B=32 SearchBatchSIMD 4.49 ms/query 17.1 GF ← SIMD 4.3x! 演算律
速・exact
```




図: いまルーフラインのここーバッチ化で AI が 0.5→16 と右へ動き、演算律速側に乗った(exact・精度そのまま)。

Stage 3 – バイナリ量子化(もう一つの道: バイトを削る・近似)

なぜ: Stage 1 でメモリ斜線に張り付いた。ルーフラインの指示は「AI を右へ=1バイトあたりの仕事を増やす(バイトを削る)」。

キャッシュ戦略は再利用が無いので効かない → データ表現そのものを変えます。

float32 を符号1bitに量子化すると 1ベクトル 1536→48 byte(1/32)。距離は内積をやめ、XOR+popcount のハミング距離(違うビット数)へ。

```
// internal/vec/hamming.go
func Quantize(v []float32, out []uint64) { // float32 → 符号1bit
    for i, x := range v {
        if x > 0 {
            out[i/64] |= 1 << (i % 64)
        }
    }
}

func Hamming(a, b []uint64) int { // XOR + popcount = 違うビット数
    var d int
    for i := range a {
        d += bits.OnesCount64(a[i] ^ b[i]) // OnesCount64 はスカラPOPCNT 1発=64次元/命令
    }
    return d
}
```

どうなったか: 153MB→4.8MB でキャッシュに乗り、DRAM の壁から脱出。0.62 ms = 43x。速さの源泉は SIMD ではなく「データを 1/32 にした」ことです。距離計算はスカラ POPCNT(64次元/命令)で足り、ここで AVX-512 の VPOPCNT を使っても速くなりません — 量子化後はキャッシュ常駐で popcount 律速ではなく、1ベクトルも6語と小さいから(実測 [SearchBinarySIMD](#) 0.75ms ≥ スカラ [SearchBinary](#) 0.68ms)。これは Stage 1 と同じ「計算で詰まっていない所では SIMD は効かない」というルーフラインの一貫した教訓です。

しかも、これは無条件の勝利ではありません。1bit に潰した代償で精度が大きく落ち、Recall@10 = 0.18(正解10件のうち2件弱しか当たらない)。43x は「正確な検索」を速くしたのではなく、近似に問題をすり替えた数字で、このままでは実用になりません(exact な Stage 0/1/2 とは別タスク)。

→ 次の一手: 速さは保ったまま精度を取り戻す。そこで SIMD が主役として戻ってきます(Stage 4)。

```
$ make bench2 BenchmarkSearchBinary 0.62 ms/op ← 43x。ただし... $ make recall Recall@10
binary(量子化のみ) 0.18 ← 低い! このままでは使えない
```

Stage 3: 量子化で右上へ → DRAM 壁を脱出(近似)




図: いまループラインのここ — 量子化で右上へ移動し DRAM 壁を脱出。ただし精度を犠牲にした近似(Recall 0.18)。

Stage 4 — fp32 SIMD で再採点(rerank)：精度を取り戻す

なぜ: Stage 3(量子化)は速いが Recall 0.18 で使い物にならない。速さは量子化で確保したまま、精度だけ取り戻したい。作戦は2段構え — 1bit のハミング距離で粗く候補を絞り(速い)、その少数の候補だけを fp32 の正確な内積で採点し直す(正確)。絞った後なので fp32 はキャッシュに乗り、追加コストは小さい。

```
// internal/index/index.go
func (ix *Index) SearchBinaryRerank(q []float32, k, factor int) []Result {
    cand := ix.SearchBinary(q, k*factor) // ① 1bitで粗く k*factor 件に絞る(速い・不正確)
    t := newTopK(k)
    for _, c := range cand {
        t.push(c.ID, vec.Dot(q, ix.Vec(c.ID))) // ② fp32 SIMD内積で採点し直す ← Stage 1 のカーネル
    }
    return t.results()
}
```

どうなったか: Recall@10 0.18 → 0.87、速度は 0.67 ms ≈ 40x(ほぼ量子化のまま)。ここで効いている `vec.Dot` は Stage 1 で書いた SIMD カーネルそのもの。つまり SIMD は「不要」だったのではなく、「速くて正確」を成立させる精度側の主役でした。

これが実運用のベクトル検索の定石(量子化で粗く絞る → 高精度な距離で rerank。Faiss / Qdrant / ClickHouse QBit と同系統)。速度(量子化=横) × 精度(SIMD内積=縦)の二本柱で、はじめて「速くて正確」に届きます。

```
$ make recall SearchBinaryRerank 0.67 ms/op ≈40x Recall@10 0.87 ← 速くて正確(SIMD内積で精度復元)
```




図: 速度の位置は Stage 3 と同じ。勝負は速度軸ではなく精度軸(Recall 0.18→0.87)で、ここで SIMD 内積が効く。


持ち帰り — さらに右上へ(このリポでは未実装)

なぜ: Stage 2 でキャッシュに乗った後、さらに右上(演算律速側)へ行くには? 引き出しは3つ。int8 量子化(転送4→1byte で AI をもう一段上げる)、クエリのバッチ化(DB1本のロードを B回再利用 → $AI \approx 0.5 \times B$ 、リッジを越えて演算律速側=実質 GEMM 化。ここで初めて幅・FMA が再び効く)、変えた表現の上でまた効く AVX-512 VPOPCNT(Uint64x4.OnesCount)。どうなる(想定): 図ではさらに右上へ動く(数値は卓上)。本リポでは未実装で、ルーフラインモデルの延長として示します。

06 ルーフライン駆動の最適化ループ

- 1 測る — GFLOP/s と転送量を取る(make roofline、カーネル単体と全探索の2粒度)。
- 2 AI を計算して点を置く — flop/byte を出して図上にプロット。
- 3 当たっている天井を特定 — メモリ斜線か/演算横線か/そもそもどちらにも未達か。
- 4 その天井を狙う手だけ打つ — 未達なら命令並列性(SIMD化・呼び出し境界の掃除)、メモリ斜線なら AI を上げる(量子化・バッチ)、演算横線なら幅・FMA・命令削減。

Stage 0→1 は「縦線上を上る(実装効率)」、Stage 2 は「横に動く(データ表現)」という別軸の動き。ルーフラインはこの2軸を一枚で見せてくれるのが価値で、「壁に張り付く → 右へ逃げる」の流れが図のトレースとして辿れる。この4手のループを図にまとめると次のとおりです。



税金が消えます(命令自体のコストは小さく、差し引きで大きく得をする — ただし後述のとおりベンダー差はある)。

ペナルティの正体(世代で違う・ここ重要): 教科書でよく語られる「一度きりの大きな遷移ペナルティ(上位状態をセーブ/リストアするモード切替)」は Sandy/Ivy Bridge～Haswell 世代の挙動です。Skylake 以降の modern Intel では仕組みが変わり、もう上位状態を保存せず、dirty 状態で実行するレガシー SSE 命令1個ごとに false dependency(上位ビットへの偽の依存)+ マージ(blend) μ op が挿入される形になっています。本ページのテスト機 AWS c7i(4th Gen Xeon Scalable = Sapphire Rapids)はまさにこの後方で、実測した「呼び出しごとの固定費 $\approx 145\text{ns}$ (550cyc)」は、この per-instruction ペナルティの蓄積を VZEROUPPER がまとめて消していると読むのが正確です。

Go 固有の事情: Go 1.26 の archsimd はこの VZEROUPPER を自動挿入しません。本来コンパイラが境界を管理して入れてくれることを期待したいところで、実際 [golang/go#77647](https://golang.org/go#77647) でも「intrinsics はコンパイラ管理だから VEX 遷移は面倒を見てくれるはず...?」という未解決の問いとして挙がっています。現状 objdump で生成コードを見ても VZEROUPPER は1個もなく、3行のアセンブリ `vzeroupper_amd64.s` を自作して境界で呼ぶのが回避策。下の register spill と同根のコード生成の未熟さで、これも将来 Go 側で解消される見込みです。

どこまで確かか(正直に): 「VZEROUPPER 1命令で同一コードが7倍速くなった」は実測で確認済み(167→23ns)。ただし効果の大きさはベンダー・世代依存で、本ページの値は modern Intel(Sapphire Rapids)のもの。AMD Zen には Intel 型の遷移ペナルティが基本的に無く、むしろ VZEROUPPER 自体が高コストな世代もある(=同じ7倍は出ない)。また 550cyc の固定費を命令単位まで分解したわけではなく、dim スケーリングで固定費を分離 → VZEROUPPER 投入で7倍を確認、という状況証拠による特定です。生ログは `../dev/OPTIMIZATION_LOG.md` の Step 4。


隠れ天井②: なぜ FMA は AVX2ピークの約1/3か — register spill

演算天井(AVX2)は理論 $\sim 120 \text{ GFLOP/s}$ (2 FMA/cyc $\times$ 8レーン $\times$ 2flop $\times$ 3.75GHz)。実測は 39 GF = その約 1/3(33%、0.65 FMA/cyc)。AI=0.5 の深いメモリ律速なのでこの低さは結論を変えないが、原因は面白い。objdump で内側ループを見ると、独立なはずのアキュムレータ12本(4本版でも同様)が全部レジスタに置けず、毎回スタックへ退避(register spill)され、同じ1本のレジスタを使い回していた。FMA 1個ごとに load+store が必ず付くので、(1) load/store ポートが先に飽和し、(2) 次の周回の load が今回の store を待つ(store-to-load forwarding $\sim 5\sim 7\text{cyc}$)。アキュムレータを増やすほど隠れるので 4本=23GF < 12本=39GF と増える — 「待ち時間律速」の指紋です。これを図にすると次のとおりです。

なぜ Go の FMA は AVX2ピークの約1/3か — register spill

「レジスタに収まらない/置けない値をメモリ(スタック)へ追い出す」のが register spill


理想: レジスタ常駐で並列



12本が各レジスタに居座り
2つのFMAユニットを埋める

AVX2 理論ピーク ~120 GF

実際: Go 1.26 archsimd



39 GF = AVX2ピークの ~33%

原因はコンパイラのレジスタ割り当て(VZEROUPPER未挿入と同根)。ハード限界ではない。
→ Go 1.27 で改善見込み (golang/go #76969, #78753)。本リポの数値も Go 更新時に再計測する。

図: 理想はアキュムレータをレジスタに置いたまま回す。実際は毎回スタックへ退避(register spill)し、FMA ごとに load+store が付く。

register spill = レジスタに収まらない/置けない値をメモリ(スタック)へ追い出すこと。これはハードの限界ではなく **Go 1.26 archsimd のレジスタ割り当ての未熟さ**(VZEROUPPER を自動挿入しないのと同根のコード生成課題)。既知 issue [golang/go#76969](https://golang.org/issue/76969) と同件で、レジスタ割り当ての改善は [#78753](https://golang.org/issue/78753) など **Go 1.27 で進行中** — 将来この 39GF は上がる見込み。生ログは `../dev/OPTIMIZATION_LOG.md` の Step 6/6b。

どこまで確かか(正直に): 確認できたのは「**spill が存在する**」(objdump で 4本・12本とも FMA に load+store が付く + 上流 issue #76969)と、メモリポート律速の見積り(~0.6 FMA/cyc)が実測 0.65 とほぼ一致する点まで。「**spill さえ消せば理論ピークに届く**」は**未検証** — Go 1.26 archsimd は常に spill し Go コードでは消せないため、VZEROUPPER のような「1命令足したら7倍」の決定的な介入実験ができていない。よって本節は**強い状況証拠による推定**であって断定ではない。

```
// go tool objdump で見た内側ループ(アキュムレータ1本ぶん) 0x..e3 c5fe6f9424... VMOVDQU  
0x398(SP), X2 ← スタックから レジスタへ load 0x..74 c4e27da8d1 TESTL $0xd1, AL ← 実は  
VFMADD213PS(=FMA)。go の誤訳 0x..79 c5fe7f9424... VMOVDQU X2, 0x398(SP) ← レジスタから ス  
タックへ store
```

objdump の読み方(3点だけ): ①1行は「アドレス / 命令バイト列 / ニーモニック(命令名) オペランド」。
(SP) はスタック上の場所。②**VMOVDQU**=ベクトルのコピー(メモリ⇄レジスタ)、**VFMADD...PS**=FMA。③**落とし穴**: `go tool objdump` は新しめの命令(VEX系)を誤訳し、FMA が **TESTL \$0xd1, AL** のような化けで表示されます — **正体は左のバイト列(c4e2...)**を見れば分かります。Linux の `objdump -d` なら正しく表示されます。

スピルの見分け方: ループ内で**演算ごとに**「(SP)→**レジスタ** の load」と「**レジスタ**→(SP) の store」がセットで並んでいたら、値をレジスタに保持できず毎回スタックを往復している証拠 = register spill。理想は load/store が消えて**FMA だけが並ぶ**。

08 まとめ — この回し方で得た学び

全体を貫く地図が**ルーフライン**でした。「**縦に上る**(実装効率: SIMD・アキュムレータ・VZERoupper)」と「**横に動く**(データ表現: 量子化)」は別軸の動きで、Stage 1 でメモリの壁に張り付いた瞬間に「次は縦ではなく横」と図が手を選んでくれました。個別の学びは:

- ① **ルーフラインで先に天井を見る** — AI=0.5 はリッジの遙か左。1行も書く前から「メモリ律速・本命は量子化」が分かっていた
- ② **ベースラインなしに最適化を始めない** — Stage 0 で素朴な数字をまず押さえる
- ③ **カーネル単体と全体の2粒度で測る** — 問題の切り分けはここから(= 図に点を2つ打つ)
- ④ **SIMD はデータが届いてこそ** — メモリの壁の前では、幅を広げても無力
- ⑤ **速度と精度を最初から2軸で測る** — 量子化 + rerank で両立(Recall 0.18→0.87)
- ⑥ **「差が出ない」は2通り** — 仮説が違うのか、介入が届いていないのか。objdump で確かめてから結論を出す
- ⑦ **同じ指標で測り直す** — ボトルネックは層状。1枚剥がすと次が出てくる(偽の壁 → 真の壁)

そして核心 — SIMD は「だけ」でも「不要」でもなく、「**どこで効くか**」が**全て**。ルーフラインがその場所を当ててくれます:

- **演算律速なら SIMD は強い** — カーネル単体 4.6x(unsafe+VZERoupper で最大 8.7x)。さらに**クエリ**をバッチ化して exact 全探索を演算律速にすれば、**精度そのまま**で 4.3x(B=1 の 1.6x から一変・Stage 2)。これが「**Go+SIMD で速くなった**」の本命。
- **メモリ律速では SIMD は無力** — 全探索 B=1 は 1.6x が限界。打つ手は SIMD を磨くことではなく **AI を上げる**こと(=再利用 or バイト削減)。

- データ表現を変える(量子化)と 43x — ただし速いのはデータ削減のおかげで、距離計算に SIMD(VPOPCNT)を足しても速くならない(キャッシュ律速+小ブロック)。しかも近似で **Recall 0.18** = 単体では使えない。その精度を **fp32 SIMD の rerank** で 0.87 に戻して初めて実用になる。

まとめると速度は「AI を上げて演算律速にして SIMD を効かせる」(再利用=バッチ / バイト削減=量子化 =横)×「精度は SIMD 内積」(縦)の二本柱。実運用のベクトルDB(Faiss / Qdrant / ClickHouse QBit)と同じ設計で、ルーフラインがどちらの軸を打つべきかを一枚で教えてください。SIMD 抜きでは「速いが使えない(Recall 0.18)」止まり — 「速くて正確」は、exact なバッチ(Stage 2)と rerank(Stage 4)の SIMD があって初めて成立します。

09 原典・参照

- 原典: Williams, Waterman, Patterson, "Roofline: An Insightful Visual Performance Model for Multicore Architectures", CACM 52(4), 2009. [\[link\]](#)
- STREAM(メモリ帯域ベンチの定番), J. McCalpin. cs.virginia.edu/stream
- Empirical Roofline Toolkit / NERSC ルーフライン解説. docs.nersc.gov
- Intel Advisor(自動ルーフライン作図). intel.com
- golang/go issues: [#76969 \(spill\)](#) / [#78753 \(regalloc, Go1.27\)](#)

10 環境メモ — Apple Silicon / Docker

Apple Silicon 参加者向け： Go 1.26 の archsimd は AMD64 専用。ARM64 では `//go:build amd64` で SIMD 実装を分け、スカラ版へフォールバックさせる構成にする。当日は AMD64 ランナー(Codespaces / AWS c7i)上の共有環境を一つ用意しておく、手元のアーキ差を気にせず同じルーフライン図に全員で点を打てる。

コラム: なぜ Docker で「amd64」を指定してもダメか

Apple Silicon でも `docker run --platform linux/amd64` を使えば実際の x86 で測れる—と思いがちだが、これは落とし穴。中身は **QEMU エミュレーション**(または Rosetta 経由)で、**実際の x86 CPU ではない**。具体的には:

- ① CPU の機能問い合わせ(CPUID)を正しく真似ないので `archsimd.X86.*()` が **すべて false** → SIMD ガードがスカラ実装にフォールバックして、SIMD パスがそもそも走らない。
- ② QEMU が不安定で、ビルド中に SIGSEGV で落ちることもある。
- ③ Rosetta 経由にしても翻訳されるのは AVX/AVX2 まで。**FMA・AVX-512 は使えない**(=内積 SIMD も VPOPCNT も不可)。

つまり **linux/amd64 コンテナ ≠ 実際の amd64**。SIMD のベンチは **Codespaces(amd64 ホスト)か amd64 実機**(AWS c7i など)で測りましょう。詳細は `../dev/ENVIRONMENT_SURVEY.md`。

11 もっと知る — Go の SIMD 標準化の歩み(付録)

Go の SIMD はこう標準化された

Go は長らく SIMD を言語機能として持たず、使うにはアセンブリ(.s)か cgo が必要でした(標準ライブラリの暗号やmath系は手書き .s で SIMD 化していた)。標準パッケージ化の流れ:

- 2024-05 — proposal #67520 「SIMD intrinsics の新パッケージ」が提起される
- 2025-05 — #73787 採択。アーキ固有の intrinsics を GOEXPERIMENT 下で提供する方針が決定(まず amd64)
- 2025-12(RC1) — パッケージ名を simd → simd/archsimd に改名(#76473)
- 2026-02 — Go 1.26 で simd/archsimd(amd64)が GOEXPERIMENT=simd 付きで利用可能に
- 2026-04 — #78902 採択。移植可能・ベクトル幅非依存の上位パッケージ simd。開発は dev.simd ブランチで Go 1.27 へ

つまり層は2つになる予定です。simd/archsimd(低レベル・アーキ固有。Float32x8 等が特定の CPU 命令に 1対1 対応。本ページが使うのはこちら)と、simd(将来の移植可能 API。同じコードが amd64/arm64 で動く想定)。いずれも当面は実験的(GOEXPERIMENT=simd)で、API もコード生成も発展途上です。本ページの VZEROUPPER 未挿入(\$07)や register spill は、標準ライブラリがまだ若いことの表れでもあります。

12 用語ミニ辞典(困ったらここ)

▼ はじめての人へ — 用語ミニ辞典(30秒)。「レジスタ? AVX?」となったらここ

CPU レジスタ CPU 中の超高速な小さな作業机。計算はここで行う。数は少なく(ベクトル用は16本ほど)、メモリより桁違いに速い。	キャッシュ / DRAM データの置き場所。近い順に L1→L2→L3(キャッシュ)→DRAM(主記憶)。近いほど速くて小さい、遠いほど遅くて大きい。	SIMD 1つの命令で複数データを同時に計算する仕組み(Single Instruction, Multiple Data)。本ワークショップの主演。
AVX2 / AVX-512 Intel/AMD の SIMD 命令の世代。AVX2=256bit幅(float32 が8個並び)、AVX-512=512bit(16個)。	レーン(lane) ベクトルレジスタの中の1区画。256bit なら float32 が8レーン=8個を一度に処理できる。	FMA 掛けて足す(a×b+c)を1命令でやる積和演算。内積(かけ算の合計)で多用する。
帯域 (GB/s) 1秒間にメモリから運べるデータ量。「データを運ぶパイプの太さ」。	GFLOP/s 1秒あたりの浮動小数点演算回数(十億回)。「計算の速さ」。	算術強度 AI flop/byte = 1バイト運ぶごとに何回計算するか。小さいほど「運び待ち」になりやすい(=メモリ律速)。

サイクル

CPU の時間の最小単位。3.75GHz なら1秒に約37.5億サイクル。「速さの目盛り」。

本文で出てくる用語

レイテンシ / スループット

レイテンシ=1個の処理が終わるまでの待ち時間。スループット=単位時間あたりに捌ける量。待ち時間で詰まると遅い。

アキュムレータ

途中結果をためておく変数(レジスタ)。独立したものを複数持つと並列に計算でき、待ち時間を隠せる。

依存連鎖 / 直列化

前の計算結果を次が待つ一列のつながり。並列にできず、待ち時間がそのまま表に出て遅くなる状態。

VZEROUPPER

SIMD(広いレジスタ)を使った後、普通のスカラ計算に戻る前に上位ビットを掃除する1命令。Go 1.26 は自動で入れてくれない。

popcount / ハミング距離

popcount=ビット列の中の「1」の個数を数える命令。ハミング距離=2つのビット列をXORして1の数を数える=違うビット数。

(バイナリ)量子化

数値を粗く小さく表現すること。ここでは float32(32bit)→符号1bit。データが1/32になりキャッシュに乗る。

int8

8bit の整数。float32(32bit)の1/4サイズ。精度を少し落としてデータを小さくする量子化の一種。

VPOPCNT / VNNI

AVX-512 の専用命令。
VPOPCNT=SIMD で popcount、
VNNI=int8 の積和。「変えたデータ表現の上で効くSIMD」。

GEMM / バッチ化

GEMM=行列×行列。クエリを束ねてDB の読み出しを使い回すと実質GEMM になり、AI(計算密度)が上がる。

objdump

コンパイル後の機械語を逆アセンブルして「実際にどんな命令が出たか」を確認するツール。

Sapphire Rapids

今回計測した CPU(Intel Xeon 8488C)の世代名。AVX-512 や VPOPCNT を持つ。

ボトルネック(律速)

全体の速さを決めている一番遅い箇所。「メモリ律速」=データ搬送が、「演算律速」=計算が頭打ちの意味。

縦に上る = 実装効率(命令並列性・幅・FMA・VZEROUPPER) | 横に動く = データ表現/アルゴリズム(量子化・バッチ化)

※ 実測: AWS c7i.large / Xeon 8488C / Go 1.26.4 / 10万ベクトル×384次元(2026-06-13)。演算ピークは Go実測39/シリコン理論240、持ち帰り章のみ卓上。